


## Assingment 2 결과 보고서

2017-11621 전기정보공학부 배병욱


### Problem 2

Problem 2에서는 outlier가 hard margin SVM에 주는 영향을 주기 위한 영향을 확인하기 위해 임의의 outlier를 추가한 후 그 결과를 plot하였다. 그 결과는 다음과 같다.


Case 1. outlier  $([3.5, 1.3])$  좌측, outlier  $([3.2, 0.7])$  우측




Case 2. outlier  $([4.0, 1.7])$  좌측, outlier  $([2.7, 1.0])$  우측




Case 3. outlier  $([3.0, 1.2])$  좌측, outlier  $([3.0, 0.5])$  우측



Case 4. outlier ([5.0, 1.0]) 좌측, outlier ([5.0, 0.5]) 우측



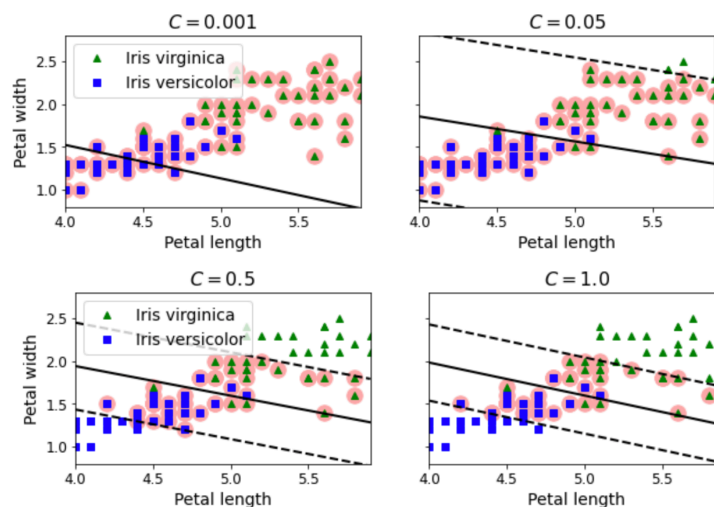
Case 5. outlier ([4.0, 1.8]) 좌측, outlier ([3.0, 0.4]) 우측




위의 Case 1~5를 확인해보면 좌측의 outlier들은 hard margin의 SVM이 불가능한 point이다. Category의 관점에서는 C3 category, slack variable의 관점에서는  $\xi_t$ 가 1보다 큰 점, 즉 misclassified된 outlier들이다. 우측의 outlier들은 본래의 hard margin의 SVM에서 misclassified되지 않았지만 margin 안의 점으로 다시 새로 SVM을 했을 때에 margin을 크게 감소시키는 점들이다. Category의 관점에서는 C2 category, slack variable의 관점에서는  $\xi_t$ 가 0과 1 사이의 점, 즉 fall inside band된 outlier들이다.

### Problem 3

Problem 3에서는 hyperparameter의 C값의 변화에 따른 SVM의 변화를 알아보도록 한다.

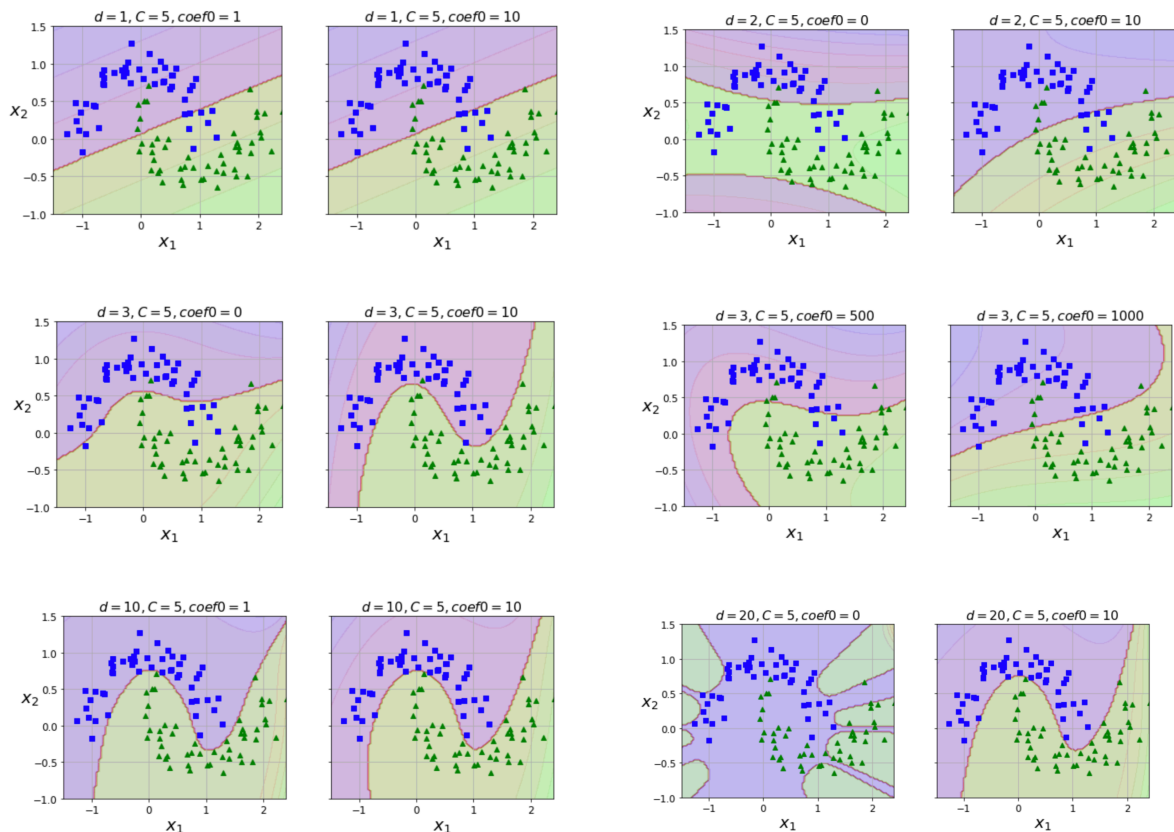




Problem 3 에서 hyperparameter  $C$ 는 cost를 의미하며 model이 얼마나 많은 outlier를 허용하는 지에 대한 수치이다. 즉  $C$ 가 클수록 noise에 대한 tolerance가 커지고 이에 따라 overfitting의 가능성이 커지게 된다. 위의 결과를 보면  $C$ 가 커질수록 margin이 점점 작아지는 것을 확인할 수 있다. 반대로  $C$ 가 아주 작은 0.0001과 같은 case에서는 모든 data들이 margin안에 들어가게 된다.  $C$ 값이 너무 작다면 margin이 커져 overfitting할 확률은 작아지지만 underfitting 되며 반대의 경우 overfitting은 커지며 underfitting은 작아지게 된다. 즉, hyperparameter  $C$ 값에 따라 tradeoff가 일어난다는 것을 확인 가능하다.

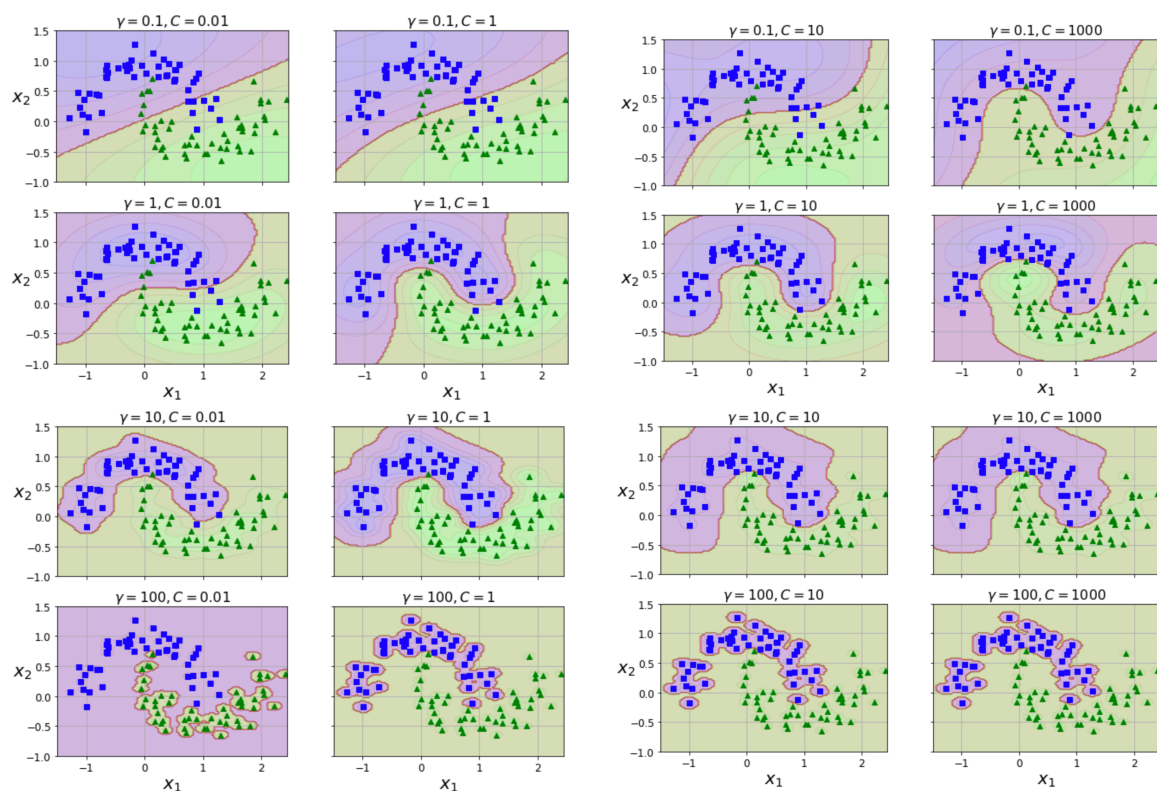
#### Problem 4

Problem 4에서는 nonlinear classification을 구현한다. 이 때의 nonlinear classification은 linearly separable하지 않은 input space를 nonlinear transform한 뒤에 linear model을 적용하는 방식을 취한다. 우선 Problem 4-1에서는 기존의 SVC의 Kernel을 polynomial로 사용한 뒤 degree와 coef0의 변화에 따른 차이를 확인한다. 이 때 polynomial에서 kernel function은  $(\gamma\langle x, x' \rangle + r)^d$ 이며, degree는  $d$ 를, coef0은  $r$ 을 결정한다.



위의 결과를 살펴보면, degree가 1일 경우에는 결국 linear separation과 똑같은 역할을 하고 있으며 degree가 커질수록 decision boundary가 더 flexible해지는 것을 확인할 수 있다. 이번 problem에서 주어진 data의 경우에는 degree가 3이상의 경우에 data를 충분히 separation할 수 있다는 것을 확인할 수 있다. Coef0의 경우에 degree가 커질수록 큰 영향을 주게 되는데 만약  $\langle x, x' \rangle$ 가 1보다 작은 수의 경우에 d가 커질수록 0에 가까워지게 된다. 이 경우에 위의 d=20, coef0=0의 경우처럼 data가 주는 영향이 거의 없어지게 될 수 있다. 그렇기에 적절한 coef0을 설정하는 것 또한 중요해지는데 이번 problem에서는 coef0이 10이라면 충분히 separable하다는 것 또한 확인 가능하다.

Problem 4-2에서는 kernel function으로 RBF(Radial bias function)를 사용하게 된다. Kernel function은  $\exp(-\gamma \|x - x'\|^2)$ 으로 hyper parameter인 gamma와 C를 변화시켜가며 그 차이를 확인한다.



Hyperparameter인 gamma는 각각의 training data가 얼마나 멀리까지 영향을 끼치는지를 결정한다. 위의 결과를 보면 gamma값이 작을 경우에 각각의 data가 굉장히 큰 영향을 끼치는 것을 확인할 가능하며 클 경우에는 그 점 주위에서 영역이 형성되는 것을 확인할 가능하다. C는 Problem 3에서 알 수 있듯 정확한 classification과 margin의 trade-off를 결정하는 수치이다.

gamma가 작은 값을 갖게 된다면 맨 위의 좌측 결과에서 볼 수 있듯 model이 linear classification과 유사한 형태를 띄게 된다. 아주 큰 C를 주지 않는 이상 data가 underfitting된다는 것을 알 수 있다. 반대로 gamma가 큰 값을 갖게 된다면 각각의 data는 거의 자기 자신과 아주 근접한 data만을 포함하게 된다. 이 경우에 C값이 변화해도 overfitting된다는 것을 알 수 있다.

위의 결과를 통해 gamma가 10일 경우에 가장 잘 classification됨을 알 수 있는데 이 경우에 C가 1에서 1000까지의 큰 변화를 주어도 모델에 큰 차이가 없음을 확인할 가능하다. 즉, 적절한 gamma를 통해 이미 잘 regularized된 모델에는 C가 영향이 적다는 것을 알 수 있다.